

# **Aprendizaje No Supervisado aplicado a la Clasificación de Competencias de Maestros del Sistema Educativo Colombiano**

## **Integrantes:**

Edgar Javier Abril Duran  
Jorge Esteban Caballero

Rebeca Gamboa Venegas  
Jesús Parada Perez

## **Resumen**

Los modelos de Machine Learning y la inteligencia artificial son cada vez más usados en el campo de la educación, en particular en las áreas de evaluación y enseñanza. En el presente trabajo, se usará un dataset de la Fundación Future Education con información sobre la clasificación de competencias de docentes: tiene respuestas a una encuesta de 20 preguntas realizada a un grupo de maestros, contiene además su información socio demográfica. Esta encuesta se usa para obtener el nivel de desempeño en 5 competencias para docentes y posteriormente, usar esa información para dirigir procesos formativos de los mismos. Usando metodologías de aprendizaje no supervisado, tales como sistemas de recomendación o Clustering, se espera encontrar nuevos patrones en la información que permitan dirigir de mejor manera los esfuerzos de capacitación para estos docentes, además de evaluar la pertinencia del instrumento de medición.

## **Introducción**

Los sistemas educativos latinoamericanos presentan una amplia diversidad de enfoques y desafíos. A lo largo de la región, se observan diferencias en la calidad y accesibilidad de la población a la educación. El avance tecnológico, la globalización y una profunda transformación de la sociedad y los mercados, coloca a la educación latinoamericana en aprietos, ya que para hacer frente a estos desafíos requiere una transformación de los sistemas educativos, que son el motor de desarrollo y movilidad social en América Latina.

La fundación Future Education (se modifica el nombre real de la entidad por confidencialidad), es una organización colombiana con presencia en todo el territorio nacional que tiene como propósito promover prácticas innovadoras en la educación. Dentro de sus proyectos se encuentra la aplicación de una encuesta en la que busca medir la percepción de los maestros/docentes/agentes educativos frente a algunas de las Competencias del Siglo XXI identificadas en el marco del capítulo latinoamericano del proyecto ATC21s por sus siglas en inglés "Assessment and Teaching of 21st Century Skills" de la Fundación Omar Dengo.

Este instrumento consta de 20 preguntas asociadas a las siguientes competencias:

- Creatividad e innovación.
- Pensamiento crítico.
- Resolución de problemas.
- Comunicación.
- Trabajo colaborativo.

Este instrumento fue diseñado y aplicado a una muestra de 5270 docentes en cada institución educativa o centro de desarrollo infantil. En la construcción del instrumento, además de los resultados del proyecto ATCS21s, un equipo de expertos de la organización fue el encargado de diseñar las preguntas para evaluar cada competencia. Pero hasta la fecha no se han implementado los pasos que establecen Fabila, Minami & Izquierdo (2013) correspondientes a la fiabilidad y

validez de la escala, y no se han realizado los análisis factoriales confirmatorios o exploratorios que permitan identificar las categorías conceptuales en las que se encuentran agrupadas los ítems.

En este proyecto se aplicarán técnicas de aprendizaje no supervisado para el análisis de los resultados a través de la exploración y análisis de posibles clústers para la toma de decisiones. Específicamente se espera en un primer momento, evaluar el instrumento de recolección de la información utilizando **técnicas de reducción de dimensionalidad, como PCA**, para observar si es posible realizar ajustes a la encuesta que generen información de mayor calidad y se confirmen o recomienden otras categorías de agrupación.

En un segundo momento, se espera encontrar grupos no conocidos, por medio de **técnicas de clustering**, de competencias multidisciplinares de acuerdo con las respuestas a sus preguntas. Utilizando estos grupos, se planea enfocar los esfuerzos de capacitación de acuerdo con estas necesidades, al estilo de un sistema de recomendación. Otra opción puede ser encontrar grupos con niveles de competencias similares, dando un “Score” basado en los grupos de respuestas de preguntas y enfocando la educación de acuerdo con el “alumno típico” de cada uno de estos grupos. El alcance de este proyecto llega hasta la obtención de estos grupos, y la validación de los grupos obtenidos, y por tanto, dar respuesta la pregunta: ¿Existen grupos formados por las respuestas y características socio demográficas de los docentes suficientemente separados para a futuro dar recomendaciones o asignar niveles de competencias multidisciplinares para brindar educación especializada?

Al potenciar los esfuerzos de capacitación de los docentes en las competencias dadas, se puede llegar a agilizar la mejora en la calidad de educación de América Latina: con una clara definición de las competencias del futuro y una capacitación adecuada de los docentes y tutores, se logra que los alumnos alcancen más rápidamente y con una mejor calidad las herramientas necesarias para su formación y preparación. Este tipo de acercamientos hasta ahora han empezado a emerger en América Latina, por lo que se considera un caso interesante para la aplicación de estas metodologías.

### **Revisión preliminar de antecedentes en la literatura**

En la literatura, se han tenido acercamientos más que todo enfocados a estudiantes, cómo en el documento desarrollado por Bagunaid et al en el 2022. Aquí, los autores utilizan diversas metodologías para llegar a un puntaje que se usa clustering por DBSCAN con distancia Mhalanobis. Luego, se hace un ajuste para el desempeño individual del estudiante y esta información procede a un sistema de recomendación para brindar opciones de aprendizaje adicional a los estudiantes. Igualmente, en el documento mencionan en su revisión de literatura que en las evaluaciones de estudiantes no se suele tener en cuenta las recomendaciones, sino que se da un puntaje que no necesariamente tiene en cuenta sus competencias individuales. Este puede ser un buen acercamiento al problema en cuestión y el agrupamiento de competencias por medio de DBSCAN.

Revisando el Systematic Review para el Student Assessment de González-Calatayud, se observa que no existen contribuciones significativas en América Latina sobre el uso de inteligencia artificial para evaluar al estudiante, hasta su publicación en junio del 2021. No obstante, en 15 de los 22 papers que eligieron se tocan temas de Inteligencia Artificial para el assessment formativo, además muestran 10 papers que tratan del scoring automático de competencias afines a las evaluadas en la encuesta usada en este proyecto (por ejemplo, en Kaila et al. se evalúa el trabajo colaborativo).

### **Descripción detallada de los datos:**

### Tamaño y características de la base de datos:

Los datos recopilados entre 2022 y 2023 por la Fundación Future Education capturan 5270 encuestas, con un total de 33 variables, mostradas a continuación:

#### Imagen 1. Lista de variables en la base de datos

```
Index(['ID', 'Year', 'Mes', 'solucion', 'regional', 'departamento',  
      'ubicacioninstitucion', 'cargo', 'edades', 'formacion', 'sexoinscrito',  
      'Marca temporal', 'formulario', 'p1', 'p2', 'p3', 'p4', 'p5', 'p6',  
      'p7', 'p8', 'p9', 'p10', 'p11', 'p12', 'p13', 'p14', 'p15', 'p16',  
      'p17', 'p18', 'p19', 'p20'],  
      dtype='object')
```

donde:

ID: identificador de la encuesta

Year: año de aplicación de la herramienta

Mes: mes de aplicación de la herramienta

solucion: programa implementado para el fortalecimiento de capacidades

regional: ubicación geográfica regional

departamento: ubicación geográfica departamental

ubicacioninstitucion: indica si la institución está en el área rural o urbana

cargo: cargo de la persona encuestada

edades: rango de edad de la persona encuestada

formacion: formación de la persona encuestada

sexoinscrito: sexo de la persona encuestada

Marca temporal: fecha de aplicación de la herramienta

formulario: descripción del momento que se realiza la encuesta

p1 a p20: preguntas para la evaluación de competencias

### Tipos de variables

La base de datos tiene 3 variables tipo int, 1 variable tipo datetime y el resto de las variables son tipo object. Cada tipo de variable se muestra en el notebook Entrega 1\_Proyecto.ipynb

### Limpieza de datos: evaluación de datos faltantes:

Se encuentran datos faltantes en las variables: regional, departamento, ubicacioninstitucion, cargo, edades, formacion, sexoinscrito, específicamente:

#### Imagen 2. Variables con valores vacíos

```
La variable regional (object): Contiene 85(1.61%) valores vacíos  
La variable departamento (object): Contiene 1(0.02%) valores vacíos  
La variable ubicacioninstitucion (object): Contiene 1(0.02%) valores vacíos  
La variable cargo (object): Contiene 16(0.3%) valores vacíos  
La variable edades (object): Contiene 15(0.28%) valores vacíos  
La variable formacion (object): Contiene 16(0.3%) valores vacíos  
La variable sexoinscrito (object): Contiene 15(0.28%) valores vacíos
```

Se procede a eliminar los datos faltantes en la variable regional, ya que para la Future Education es importante saber a qué región pertenecen los docentes. La base de datos después de eliminar los datos faltantes tiene 5186 observaciones y 33 variables.

Se procede a realizar un análisis de los valores únicos de las variables, donde se encuentran los siguientes errores:

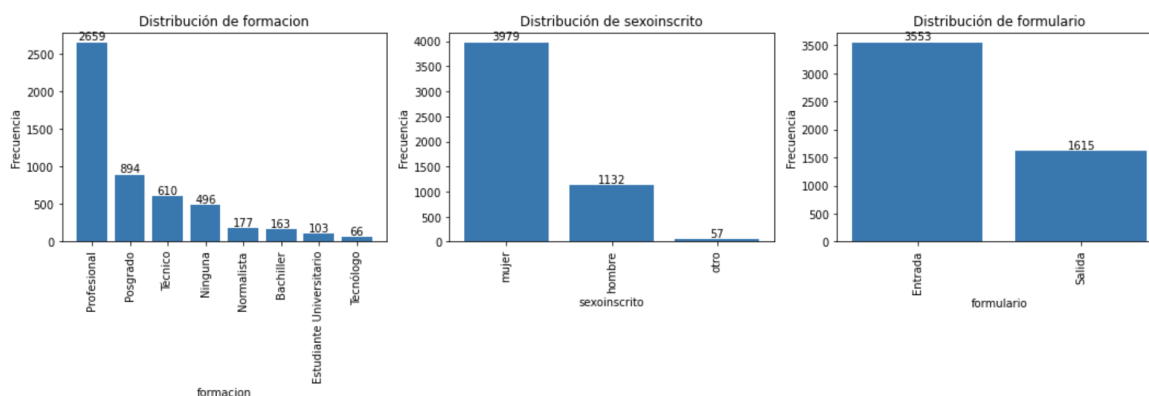
- Departamento: el dominio NINGUNO no es un valor válido y se debe imputar o eliminar.
- Ubicacioninstitucion: la ubicación ninguna no es válida, debe ser urbana o rural
- Edades: todos son docentes, maestros o agentes educativos, por lo que todos son mayores de edad; las edades 0 a 6, 7 a 14 y 15 a 17, no son válidas, se debe imputar o eliminar.
- Sexoinscrito: la opción Mujer no es válida, se debe reemplazar por mujer.

Con lo anterior, se realiza la imputación univariada que consiste en utilizar únicamente la información que posee la variable que se está imputando para poder establecer valores numéricos en las observaciones que corresponde. Además, se utiliza la moda para calcular el valor con el que se reemplazarán los datos faltantes.

### Visualización:

Para conocer a profundidad los datos, se realiza un análisis visual de la distribución de las variables tipo object. La mayoría de las personas encuestadas son mujeres, profesionales, docentes, ubicadas en regiones urbanas; la mayoría de las personas se ubican entre los 26 y 35 años. Además, la mayoría de los encuestados son de Antioquia.


Imagen 3. Distribución de las variables según sus categorías



(La totalidad de distribuciones se encuentran en el notebook Entrega 1\_Proyecto.ipynb )

Por otro lado, las variables que representan las respuestas de las preguntas son variables categóricas con valores que pueden ser transformados para su análisis, estos valores únicos son: “Nunca”, “A veces”, “Constantemente”, “Siempre”, antes de realizar la transformación es necesario invertir el valor de 9 preguntas, específicamente las preguntas 2, 4, 7, 8, 11, 14, 16, 18 y 20 para los cuales “Nunca” tendrá un valor de 1, “A veces” será igual a 2, “Constantemente”, será igual a 3 y “Siempre” igual a 4. Con ello, da para verificar si existe algún tipo de correlación entre las respuestas de las preguntas evaluadas, el gráfico anterior, no muestra correlación alguna entre las variables.

Imagen 4. Correlación de preguntas P1 a P20



### Propuesta metodología:

Se espera realizar a nivel macro el siguiente desarrollo::

1. Estandarizar y codificar los datos, preparándolos para ser usados en las metodologías dadas.
2. Generar Clusters de los datos. Dada la naturaleza de los datos, seguramente se usarán algoritmos de clustering que admitan variables categóricas codificadas. Por ahora, se planea usar al menos DBSCAN.
3. Evaluar los clusters encontrados.
  - a. Usando la clasificación actual de las competencias, revisar si existen diferencias en los niveles de competencias entre los grupos encontrados y caracterizarlos.
  - b. Evaluar la calidad de los grupos encontrados usando las metodologías apropiadas de los algoritmos usados
4. Concluir sobre los resultados
  - a. Concluir sobre la separación de los grupos y la viabilidad de a futuro aplicar sistemas de recomendación de contenido
  - b. Concluir sobre si existe información suficiente en la encuesta para dar resultados, o si por el contrario hay preguntas redundantes en la clasificación, esto por medio de la evaluación del instrumento de obtención de datos con técnicas de reducción de dimensionalidad, específicamente aplicar PCA a dicha información.
  - c. Dar conclusiones en relación con las ventajas y desventajas de no dar 5 puntajes sino la pertenencia a un grupo de competencias multidisciplinarias.
  - d.

## Referencias

- Bagunaid, W., Chilamkurti, N., & Veeraraghavan, P. (2022). AISAR: Artificial Intelligence-Based Student Assessment and Recommendation System for E-Learning in Big Data. *Sustainability*, 14(17), 10551. doi: 10.3390/su141710551
- González-Calatayud, V., Prendes-Espinosa, P., & Roig-Vila, R. (2021). Artificial Intelligence for Student Assessment: A Systematic Review. *Appl. Sci.*, 11(12), 5467. doi: 10.3390/app11125467
- Minn, S. (2022). AI-assisted knowledge assessment techniques for adaptive learning environments. *Computers and Education: Artificial Intelligence*, 3, 100050. doi: 10.1016/j.caeai.2022.100050
- Kaila, E., Kurvinen, E., Lokkila, E., & Laakso, M.-J. (2016). Redesigning an Object-Oriented Programming Course. *ACM Trans. Comput. Educ.*, 16(4), 1–21. doi: 10.1145/2906362
- Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for machine learning*. Cambridge University Press.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT press.
- Hastie, T., Tibshirani, R., & Friedman, J. H. (2009). *The elements of statistical learning: data mining, inference, and prediction*. 2nd ed. New York: Springer.
- Murphy, K. P. (2012). *Machine learning: a probabilistic perspective*. MIT press.
- Peña, D. (2002). *Análisis de datos multivariantes (Vol. 24)*. Madrid: McGraw-hill.
- Amat Rodrigo, Joaquín (2022). *Clustering con Python*. Available under a Attribution 4.0 International (CC BY 4.0) at <https://www.cienciadedatos.net/documentos/py20-clustering-con-python.html>. (Accedido 9 de Enero 2022)
- Hastie, T., Tibshirani, R., & Friedman, J. H. (2001). *The elements of statistical learning: Data mining, inference, and prediction*. New York: Springer.
- Jones, Aaron; Kruger, Christopher; Johnston, Benjamin. *The Unsupervised Learning Workshop: Get started with unsupervised learning algorithms and simplify your unorganized data to help make future predictions*. Packt Publishing. Kindle Edition.
- Kaufman, L. & Rousseeuw, P. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*, Wiley, New York.
- Macnaughton Smith, P., Williams, W., Dale, M. & Mockett, L. (1965). Dissimilarity analysis: a new technique of hierarchical subdivision, *Nature* 202: 1034–1035.
- Pedregosa, F. et al., 2011. Scikit-learn: Machine learning in Python. *Journal of machine learning research*, 12(Oct), pp.2825–2830.
- Fabila, Angelica & Minami, Hiroe & Izquierdo, Jesús. (2013). La escala de Likert en la evaluación docente: acercamiento a sus características y principios metodológicos. *perspectivas docentes*. 52.